Éditer numériquement *Li histoire de Kanor et de ses freres* ms. BnF fr. 1446

Florian-Pierre Zanardi
`github.com/kanor-c7s`

30 mai 2025

Résumé

Ce document est édité dans le cadre de la validation du certificat en Humanités Numériques de l'Université de Genève, session juin 2025. Il présente mon projet d'édition documentaire numérique du roman Li histoire de Kanor et de ses freres *qui est une partie de mon travail de thèse. On y présente les données générées lors de ce travail, le processus d'édition allant de la récupération des données documentaires de base, de l'océrisation et de sa normalisation, jusqu'à la conception des choix d'édition en XML-TEI, et le site créé.*

1 Introduction

Le Roman de Kanor est la dernière continuation romanesque du *Cycle des Sept Sages de Rome*. Parmi les six témoins qui nous sont parvenus, le ms. BnF fr. 1446 (C) donne à lire une version non-cyclique, qui contient une «rechapitulation» et une version remaniée des romans de *Pelyarmenus* et de *Kanor*[1]. La nature atypique de sa composition ainsi qu'une lecture peu aisée du manuscrit l'ont placé en retrait par rapport aux autres témoin de la tradition. La version C pose toutefois des problèmes de critique textuelle, quant l'antériorité du manuscrit[2] par rapport aux autres témoins, et littéraire, quant à sa composition, qui en font un document riche et fascinant. Notre projet de thèse consiste en partie à proposer une édition documentaire de cette version non-cyclique du roman.

Si le *document* tel qu'il est présenté par le ms. BnF fr. 1446, et que notre édition numérique restitue, ne manque pas d'intérêt en soi, nous avons tenté de garder comme horizon possible une édition numérique critique du *texte* du *Roman de Kanor*. Préalable et nécessaire, comme le souligne Frédéric Duval[3], les fondements de cette édition documentaire se veulent être des prolégomènes à une vraie édition *critique* du *Kanor*.

Le temps, la tradition philologique du cycle et les contraintes du cadre académique dans lequel prend place ce projet doivent toutefois nous rappeler que l'idéal d'une édition consiste surtout à la mener à son terme.

2 État de l'art

Le projet FNS *Canoniser les Sept Sages*[4] souhaite à terme produire une base de données qui inclut tous les témoins du cycle. Une équipe a déjà OCRisé le *Pelyarmenus* et a fourni une édition `XML-TEI`[5].

Le témoin C du *Roman de Kanor* n'a jamais été édité et n'a encore fait l'objet d'aucun traitement numérique, alors que le manuscrit 1446 renferme plusieurs œuvres qui intéressent la critique et l'édi-

tion[6].

3 Le corpus du projet

Le corpus se compose de 70 folios issus du ms. BnF fr. 1446[7] qui forment l'intégralité du roman. Les images ont été récupérées par le point d'accès `IIIF` grâce au script `Pyllica`[8]. Deux familles de mains sont repérables, notamment de type gothique *littera hybrida*. Le trait est rapide et la préservation des traces écrites médiocre.

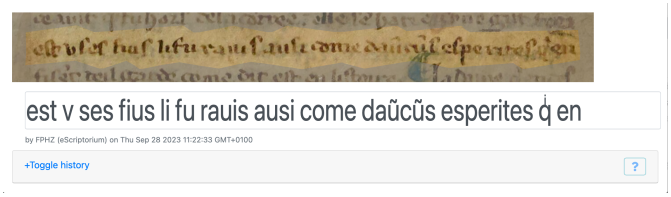

Figure 1 – *Exemple de la `main1`*

4 Modèles utilisés

Nous avons utilisé un modèle de segmentation pour le zonage du document et un modèle `OCR` pour la reconnaissance automatique. Seul le modèle `OCR` a été entraîné.

4.1 Préparation des données

Les données du corpus ont été préparées sur une instance `eScriptorium`[9] des serveurs de l'INRIA en 2023. La BnF propose une API `IIIF` ; nous avons ainsi utilisé le *manifest* `IIIF` de notre manuscrit pour pouvoir récupérer les images du scan sur `eScriptorium`. Cette instance utilisait au moment de l'entraînement le moteur `OCR Kraken 4.3`[10]. Les données générées ont été soumises au catalogue HTR-United[11] afin d'être éventuellement utilisées pour entraîner d'autres modèles.

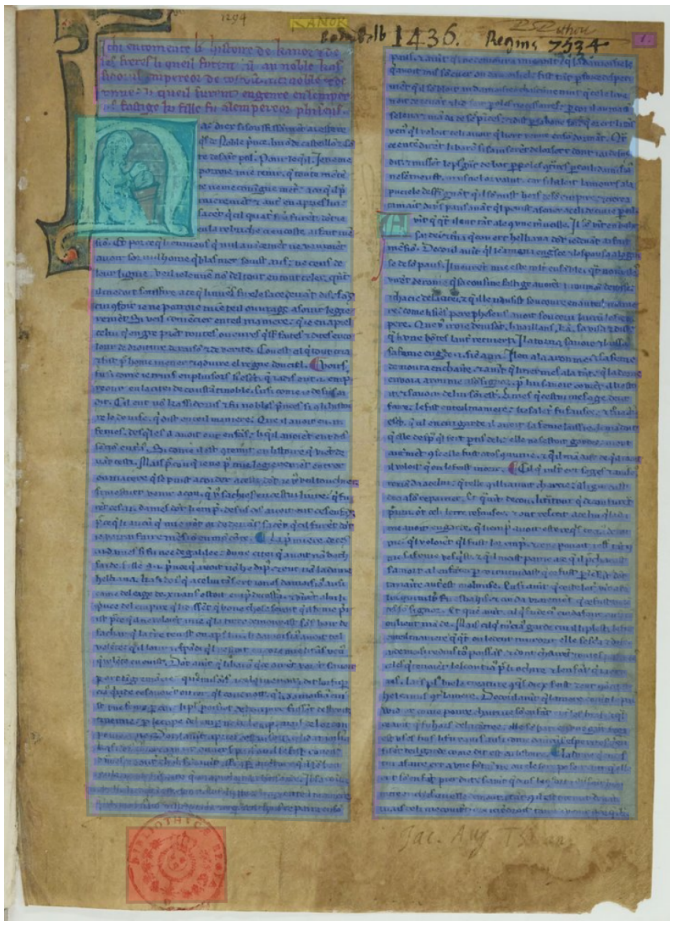

Figure 2 – *Zones retenues f. 1*

4.2 Modèle de segmentation

Le modèle `segmOntoCorpusSegmentation`[1] a servi à la segmentation automatique du document (régions et lignes). Ce modèle, issu du projet `Gallic(orpor)a`, est un enfant du modèle `blla.mlmodel` qui est le modèle de segmentation par défaut de `Kraken`. Une reprise manuelle au niveau des lettrines a été nécessaire ponctuellement pour les régions.

Règles de segmentation L'ontologie des zones respecte le vocabulaire contrôlé de la documentation `SegmOnto`. Les zones retenues sont réduites au minimum : `Title`, `MainZone`, `DropCapitalZone`, `NumeringZone` et `StampZone`[12].

1. `github.com/Gallicorpora`

4.3 Modèle de transcription

Une première transcription a été générée à partir du modèle standard `cremma-medieval-lat-AF-best`[13]. Ce modèle est entraîné à partir d'un jeu de données centré sur des manuscrits des XIIIe et XIVe siècles en ancien français et en écriture gothique *textualis*.

Règles de transcription Notre édition documentaire se veut assez fidèle au document pour pouvoir en rendre compte de manière précise au niveau de la lettre. Nous avons déterminé qu'une transcription graphématique répondait à la fois à l'exigence de précision au regard du document, mais aussi à l'établissement du texte.

Pour corriger, entraîner puis établir les données, nous avons suivi la synthèse d'Ariane Pinche pour les manuscrits du Xe au XVe siècle en français[14]. Ce document propose un ensemble de préconisations qui permet de normaliser les règles adoptées pour la création des vérités de terrain. Nous avons suivi une transcription pseudo-graphématique qui conserve ponctuation originale, abréviations et graphies, mais non les tirets de fin de ligne ni les espaces entre morphèmes élidés (ex. *quil* et non *qu il*). La nature de notre projet d'édition a impliqué un contrôle manuel systématique de tous les folios sur l'interface eScriptorium.

Entraînement Ariane Pinche a mené deux entraînements à partir des données contrôlées (*golden dataset*) que nous avons créées. Le premier sur la base des 10 premiers folios, puis des 20 premiers. Le dernier modèle entraînait avait une *accuracy* de 86%. L'important de la production de données fiables réside toutefois plus dans leur partage à une communauté de chercheurs que dans l'obtention immédiate d'un modèle performant.

Résultats Les fichiers `ALTO` de la transcription sont disponibles sur le GitHub du projet, ainsi que le modèle `Kanor` du ms. 1446. Avant la fin de notre projet d'édition, nous souhaitons faire une dernière relecture intégrale du manuscrit ; dès lors, nous entreposerons ces données dans une archive sur Zenodo.

Ces fichiers `ALTO`, ainsi que les images du manuscrit récupérées sur le serveur `IIIF` de la BnF, servent de base à une visionneuse que nous avons codée sur le site de l'édition. En l'état, cette fonctionnalité permet d'assurer le contrôle visuel de la transcription, la visibilité de l'agencement de la matière textuelle dans le document, et ce sur toute l'étendue du manuscrit, et la présentation d'un support utile dans un cadre pédagogique de diffusion du savoir paléographique.

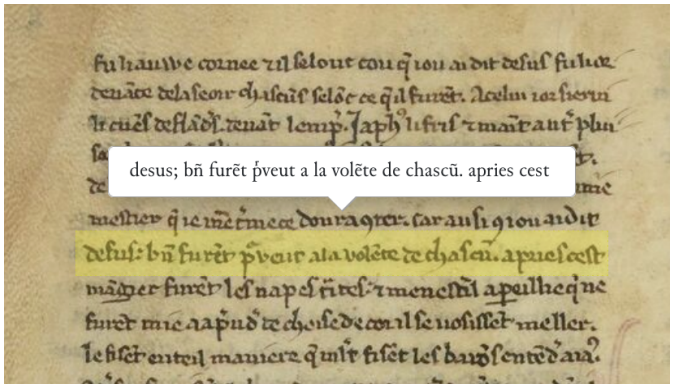

Figure 3 – *Visionneuse image > ALTO*

5 Normalisation du corpus

Un document «Principes de transcription» recense les différentes règles appliquées pour obtenir l'édition normalisée, qui est notre support de travail pour l'étude littéraire. Ces principes suivent les conseils actuels en matière d'édition de texte, notamment ceux de Pascale Bourgain et Françoise Vielliard[15].

La normalisation, bien qu'elle ait profité des pos-

sibilités offertes par des expressions régulières basiques, n'a pas été automatisée.

6 Une édition XML-TEI

Le pan numérique de cette édition entre dans un projet doctoral plus vaste dont il n'est qu'une fraction. Nous avons borné nos prétentions à une édition documentaire qui comprend plusieurs aspects.

6.1 Objectifs

La création de cette édition numérique répond à un besoin de compréhension littéraire et littéral de ce témoin complexe, ainsi que de son intégration spécifique dans un cycle romanesque important au Moyen Âge. Quelques objectifs : unifier les différents témoins du Cycle grâce à un alignement des unités textuelles ; unifier les références internes (entités nommées) en réduisant les difficultés dues aux variations graphiques ; mettre au jour la richesse lexicologique de ce document qui se distingue des autres témoins par son marquage diatopique.

6.2 Moyens

L'édition documentaire Nous avons respecté les guides d'encodage de la TEI [2] et utilisé le logiciel Oxygen XML Editor.

La rédaction d'un modèle ODD commun avec l'équipe *Pelyarmenus* permet une opérabilité de nos éditions. Un guide ODD propre au *Kanor* est rédigé pour rendre explicites les problèmes, nombreux, et les choix retenus[16]. Ce guide présente et justifie ces choix.

Un exemple efficace de cette collaboration réside dans la constitution d'une base commune de noms propres (personnages/lieux) avec les balises `<person xml:id="xxx">` et `<place xml:id="xxx">`.

2. https://tei-c.org/

Le glossaire Notre travail d'édition comporte un approfondissement de la connaissance lexicologique du texte. La dernière édition du *Roman de Kanor* ne comportait aucun travail sérieux sur cet aspect du texte. De plus, tant le marquage diatopique des formes que l'appartenance régionale des lexies rencontrées nous ont incité à fournir une étude poussée de cette dimension linguistique. Un glossaire en cours de complétion a été créé sur le site [3]. Il dispose d'une partie *consulation* et *édition* sur lesquelles environ 160 entrées sont consultables.

L'interface de consultation se double d'une fonctionnalité d'export de la base de données en `XML-TEI`. Le fichier d'export suit les caractéristiques et recommandations du projet `TEI Lex-0`. Ce projet est lui-même une adaptation approfondie des recommandations de la `XML-TEI` touchant l'encodage des données lexicographiques. Au début, nos données étaient encodées au format `JSON` dans une structure claire, mais interne au projet. Sur les conseils de Simon Gabay, nous avons converti notre base en `XML-"TEI Lex-0"` dans un souci d'interopérabilité et surtout de pérennité des données.

Figure 4 – *l'entrée "meutier" du glossaire*

6.3 Résultats et limites actuelles

Résultats À ce jour, cette édition a permis de rendre lisibles un document et un texte complexes tant dans leur matérialité paléographique que dans leur construction littéraire. Les données de terrain sont décrites, centralisées et stockées sur le dépôt

3. https://lenomdelarose.fr/glossaire_kanor/

GitHub du projet, qui propose notamment un site internet [4]. Ce site intègre certaines possibilités de visionnage offertes par les choix retenus de balisage en `XML-TEI` [absence/présence des gestes d'édition, des notes, d'une résolution dynamique des entités nommées (uniquement les noms de personnages pour le moment)]. Par ailleurs, ce travail a permis d'intégrer le témoin C dans l'alignement synoptique mené par Camille Carnaille. Un autre site, intégrant du contenu dynamique en `PHP` incompatible avec les serveurs de GitHub, offre un accès au glossaire et à la visionneuse réversible du manuscrit.

L'adaptation à notre projet de la base d'entités nommées du *Pelyarmenus* ainsi que la conception d'un glossaire dont l'encodage le rend interopérable avec les éditions à venir d'autres témoins du roman sont deux possibilités proprement numériques qu'il nous a semblé intéressant d'explorer en complément du processus d'édition du texte.

Limites actuelles Si l'on s'en tient à l'idéal d'une *édition critique numérique* tel qu'il a pu être décrit par Frédéric Duval, notre projet doit encore mûrir en termes d'harmonisation des moyens techniques dans un dessein éditorial mieux cerné. En effet, la part numérique du projet alterne encore entre une volonté d'exploiter au maximum des outils nouvellement acquis et une perspective éditoriale encadrée par un schéma académique assez rigide, mais qui ne demande qu'à être actualisé. Si les données produites jusqu'à présent fournissent une bonne base de travail pour exploiter ce document, une réflexion plus aboutie sur la dynamique d'ensemble de notre édition doit être formulée. En l'état, l'hétérogénéité des dépôts de données (GitHub et serveur personnel) et le caractère fermé et non pérenne du site personnel (glossaire) sont des freins à la pleine maturité du projet. On espère y remédier, notamment en poursuivant notre formation pour adopter la plateforme de publication `TEI Publisher`.

4. `https://kanor-c7s.github.io/`

Remerciements

Nous souhaitons apporter un remerciement particulier à Ariane Pinche pour le temps passé à entraîner un modèle sur le ms. 1446 ainsi que l'INRIA pour la mise à disposition gratuite d'une instance `eScriptorium`. Camille Carnaille (et le groupe d'édition du *Pelyarmenus*) pour les nombreux échanges concernant l'apprentissage du `XML-TEI` et les choix de balisage communs aux deux projets. Simon Gabet pour les cours dispensés pour le certificat, le temps individuel et les discussions personnelles qui m'ont permis de découvrir des références et projets stimulants.

Références

[1] Florian-Pierre Zanardi. "La «rechapitulation» du Cycle des Sept Sages et le *Roman de Kanor* dans le manuscrit Paris, BnF fr. 1446 : éditer une rédaction alternative". In : *XVIIe Congrès de la Société Internationale de Littérature Courtoise*. Université de la Colombie-Britannique, Vancouver, Canada, 24-28 juill. 2023.

[2] Albert Henry. "Burir et sa famille en ancien français". In : *Festschrift Kurt Baldinger zum 60. Geburtstag*. Tübingen, 1979, p. 511-522.

[3] Frédéric Duval. "Pour des éditions numériques critiques. L'exemple des textes français". In : *Médiévales* 73 (automne 2017). Mis en ligne le 28 février 2019, consulté le 28 mai 2025. doi : `10.4000/medievales.8165`. url : `http://journals.openedition.org/medievales/8165`.

[4] Yasmina Foehr-Janssens et Simone Ventura. *Canoniser les Sept Sages : Livre, langues, écriture sérielle (XIIIe-XVe siècles)*. https://www.unige.ch/c7s. Projet financé par le FNS et le FNRS.

[5] Camille Carnaille, Prunelle Deleville et Sophie Lecomte. *Canoniser les Sept Sages de Rome (C7S)*. https://github.com/CycleDes7Sages/CycleDes7Sages.github.io. Projet financé par le FNS (Suisse) et le FNRS (Wallonie-Bruxelles).

[6] Nicolas Chardonnens et Béatrice Wahlen. "Heurs et malheurs d'un brouillon. Des contes desrimez de Baudouin Butor à Perceforest". In : *Lieux de mémoire antiques et médiévaux : Texte, image, histoire : la question des sources*. Sous la dir. de Bernard Andenmatten et al. BSN Press, 2012, p. 257-291. doi : 10.3917/bsn.ndenm.2012.01.0257.

[7] Bibliothèque nationale de France. *Manuscrit numérisé BnF fr. 1446: ark:/12148/btv1b10023851v*. https://gallica.bnf.fr/ark:/12148/btv1b10023851v. Manuscrit numérisé disponible sur Gallica, la bibliothèque numérique de la BnF.

[8] Pierre-Carl Langlais et Julien Schuh. *Pyllica : Un outil de récupération automatisée de données sur Gallica*. https://github.com/Dorialexander/Pyllica. Version mise à jour disponible sur GitHub. 2025.

[9] Benjamin Kiessling et al. "eScriptorium: An Open Source Platform for Historical Document Analysis". In : *2019 International Conference on Document Analysis and Recognition Workshops (ICDARW)*. T. 2. 2019.

[10] Benjamin Kiessling. "Kraken - An Universal Text Recognizer for the Humanities". In : *Digital Humanities Conference 2019 - DH2019*. Utrecht, The Netherlands : ADHO, 2019.

[11] HTR-United Team. *HTR-United : Catalogue de jeux de données pour la transcription et la segmentation automatiques*. https://htr-united.github.io/.

[12] Simon Gabay et al. *SegmOnto, A Controlled Vocabulary to Describe the Layout of Pages*. https://segmonto.github.io/. Version 0.9, accessed March 5, 2025. 2023.

[13] Ariane Pinche. *CREMMALab Project: Handwritten Text Recognition for medieval manuscripts*. Digital Humanities. Poster. Juill. 2022. url : https://hal.science/hal-03724041.

[14] Ariane Pinche. "Guide de transcription pour les manuscrits du Xe au XVe siècle". working paper or preprint. Juin 2022. url : https://hal.science/hal-03697382.

[15] Pascale Bourgain et Françoise Vielliard. *Conseils pour l'édition des textes médiévaux. III : Textes littéraires*. T. 4. Orientations et méthodes. Paris : École Nationale des Chartes, 2002, p. 253.

[16] Florian-Pierre Zanardi. *Guide d'encodage de la rédaction non cyclique de l'Histoire de Kanor et de ses freres d'après le manuscrit BnF fr. 1446 (C)*. https://github.com/kanor-c7s/kanor_xml_tei/blob/main/ODD/ODD-c7s-fro7.pdf. 2024.